



《人工智能与机器学习》

从 Alpha Go 和德州扑克看 AI 未来在 游戏行业的发展

小组成员 周意尧、曾夏彦泽、郭祖奕

开课学院 控制科学与工程学院

指导老师 谢磊、周建光

提交日期 2024 年 11 月 22 日

从 Alpha Go 和德州扑克看 AI 未来在游戏行业的发展

周意尧、曾夏彦泽、郭祖奕 浙江大学

摘要 近年来,人工智能(AI)在游戏中的应用取得了显著进展,从 AlphaGo 在围棋和德州扑克中展现出的卓越能力,到在 MOBA 等复杂多人游戏中的广泛应用,AI 推动了游戏行业的技术创新和发展。本文首先分析了围棋和德州扑克两种经典游戏中 AI 的不同处理方法。最后,本文还探讨了 AI 在 MOBA 等现代复杂游戏中的最新进展,并展望了 AI 在游戏行业中的发展前景。本文认为,未来 AI 在游戏中的应用将朝向更加智能化和人性化的方向发展,为玩家提供更加丰富且沉浸式的游戏体验。

关键词 AI ; AlphaGo ; 德州扑克; 强化学习; 博弈论; 游戏智能化

The future development of AI in the game industry from AlphaGo and Texas Hold 'em Poker

Yiyao Zhou,Yanze Zhengxia,Zhuyi Guo Zhejiang University

Abstract In recent years, artificial intelligence (AI) has made significant progress in gaming, demonstrating exceptional capabilities from AlphaGo's triumphs in Go and Texas Hold'em to its broader use in complex multiplayer games like MOBAs. AI has driven technical innovation and advancement in the gaming industry. This paper first analyzes the different approaches AI takes in handling classic games such as Go and Texas Hold'em. Finally, it explores recent AI advancements in modern, complex games like MOBAs and discusses the future of AI in gaming. The paper suggests that AI's role in gaming will continue to evolve towards greater intelligence and personalization, offering players richer and more immersive experiences.

Keywords AI ; AlphaGo ; Texas Hold 'Em; Reinforcement learning; Game theory; Game intelligence

一 引言

近年来,人工智能(AI)在游戏中的应用取得了显著进展,从最早的 AlphaGo 在围棋以及德州扑克 z 这两个经典的具有挑战性的游戏中展现了卓越的能力开始。到现在 AI 在 MOBA 等游戏中的广泛应用, AI 在游戏中的应用也在不断的创新。这些技术突破不仅推动了 AI 在游戏领域的广泛应用,也为研究复杂的策略博弈提供了新的方向。本文深入分析了围棋与德州扑克 AI 的不同处理方法及其各自的应用特点,同时探讨了 AI 游戏行业的发展前景。

二 正文

1 围棋中的人工智能处理方法

围棋是一种完全信息博弈,游戏双方可以完全看到棋盘上的状态,这使得 AI 能够基于此制定精确的策略。AlphaGo 作为围棋 AI 的代表,通过结合深度神经网络(DNN)和蒙特卡洛树搜索(MCTS)来处理围棋的复杂决策问题^[1]。

1.1 深度神经网络与蒙特卡洛树搜索

AlphaGo 在人工智能领域通过深度学习技术来推动机器学习算法性能显著提升。特别是在强化学习领域,策略网络与价值网络作为两大核心组件,对于提高算法的学习效率和决策质量起到了至关重要的作用^[1]。AlphaGo 采用策略网络主要用于直接输出行动的概率分布,指导智能体在给定状态下选择最优动作;而价值网络则负责评估当前状态或状态-动作对的好坏,为策略网络提供反馈信号,帮助其不断优化决策过程。AlphaGo 在两者的结合使用中不仅能够有效解决单个网络模型在面对复杂任务时遇到的局限性,还显著提升算法的整体性能^[2]。通过这种结合, AI 能够在众多可能的落子路径中快速找到最优的选择^[3]。




Fig. 1 神经网络训练流程图和结构

AlphaGo 同时还采用了蒙特卡洛树搜索(Monte Carlo Tree Search, MCTS)算法,这种算法综合了随机抽样技术与决策树构建策略,该算法在解决复杂决策问题领域得到了广泛应用。MCTS 算法主要由四个核心步骤构成:选择(Selection)、扩展(Expansion)、模拟(Simulation)和回溯(Backpropagation)。在选择阶段,算法自根节点起始,AlphaGo 依据特定策略递归地选择子节点,直至抵达叶节点或尚未充分探索的节点;在扩展阶段,若当前节点为叶节点,则会新增一个或多个子节点,这些子节点代表了新的游戏状态或决策选项;在模拟阶段,从新增的节点出发,执行一次或多次随机游走,直至达到游戏的终止状态或满足预设的停止条件;在回溯阶段,将模拟过程中的结果逆向传递至根节点,并据此更新各节点的统计信息,包括访问频次和平均收益等。通过不断重复上述步骤,AlphaGo 在使用 MCTS 算法计算的过程中能够逐步

提升决策路径的优化程度，进而增强决策的品质^{[4] [5] [6]}。




Fig. 2 AlphaGo 中的蒙特卡洛树搜索

1.2 自我对弈与强化学习

AlphaGo 的初始训练过程依赖于大量人类对局数据，以构建基础策略模型^[7]。该过程验证了在完全信息博弈中，自我对弈策略的有效性，即人工智能能够通过持续的尝试与优化，逐步增强其博弈能力，并最终超越人类顶级棋手。当此算法与强化学习技术相结合时，一方面，自我对弈系统能够利用现有的神经网络架构，产生更精确的评估结果，并据此生成更优质的数据集；另一方面，强化学习的神经网络模块能够利用这些优质数据进行深入训练，进而导出更优化的神经网络模型。这一机制形成了正向反馈循环，促进了神经网络性能的逐步提升，同时也推动了自我对弈在棋艺水平上的持续进步^[8]。




Fig. 3 AlphaGo Zero 中的自对弈学习

在强化学习的进程中，人工智能通过评估每一步棋的收益，逐步习得在不同棋局中作出更优决策的能力。该过程要求 AI 不断进行迭代与调优，以实现策略的持续优化。在 AlphaGo 的改进版本 AlphaGo Zero 中，DeepMind 团队采用了一种全新的独立强化学习算法^[9]，取得了更为卓越的成就。该版本以单一神经网络取代了策略网络与价值网络，并且摒弃了蒙特卡洛方法，转而采用简化版的树搜索算法来评估落子位置与胜率。在训练过程中，AlphaGo Zero 从当前盘面状态 t_s 开始，利用基于深度神经网络 f 的树搜索算法推导出落子策略 t ，其中 t 代表神经网络 f 的参数集合，并通过神经网络输出策略函数 t_p 和估值函数 t_v 。程序依据策略 t 选择动作，直至棋局结束并获得最终结果 z 。随后，利用结果 z 、估值函数 t_v 以及策略 t 和 t_p 构建损失函数 l ，以此不断更新神经网络的参数^[10]。




Fig. 4 AlphaGo 的实证评价

2 德州扑克中的人工智能处理方法

德州扑克作为一种经典的扑克游戏，种类如图 5 所示，其魅力很大程度上来源于其不完全信息的特性。在牌桌上，每个玩家只能看到自己手中的牌以及公共牌面上的牌，而无法得知其他对手的具体手牌情况。这种信息不对称性使得游戏策略的制定变得极为复杂和具有挑战性。

Name	Example	Description
Royal Flush	A K Q J 10	Straight flush from Ten to Ace
Straight Flush	K Q J 10 9	Straight of the same suit
Four-of-a-Kind	A A A A 10	Four cards of the same value
Full House	A A A K K	Combination of three of a kind and a pair
Flush	2 4 7 9 Q	Five cards of the same suit
Straight	A K Q J 10	Sequence of 5 cards in increasing value
Three-of-a-Kind	A A A K Q	Three cards with the same value
Two Pair	A A K K Q	Two times two cards with the same value
One Pair	A A K Q 7	Simple value of two card with the same value
No Pair	A K Q J 4	Simple value of the cards with no same value

Fig. 5 德州扑克^[11]

为了在这种环境下制定有效的策略，人工智能需要克服诸多困难。首先，AI 必须能够处理并理解这种信息的不对称性。它不能仅仅依赖自己手中的牌来做出决策，还需要综合考虑公共牌面、对手可能的牌型分布、对手的历史行为等多种因素。这种综合考虑要求 AI 具备高度的抽象思维能力和逻辑推理能力^[12]。

为了应对这种不确定性，AI 结合了多种先进的方法和技术。其中，博弈论为 AI 提供了理论支持，使其能够理解和预测对手的可能行为。通过博弈论，AI 可以分析不同策略下的得失情况，从而制定出最优或次优的策略。概率推断也是 AI 在德州扑克中不可或缺的工具。通过概率推断，AI 可以估计对手手中牌的可能性，从而更加准确地评估自己的牌力和胜算。这种推断需要 AI 具备丰富的数据和先进的算法支持，以确保推断结果的准确性和可靠性。此外，强化学习方法也被广泛应用于 AI 在德州扑克中的策略制定。强化学习通过让 AI 在与环境的交互中不断学习和优化策略，使其能够适应不同的对手和牌面情况。这种方法不仅提高了 AI 的适应性，还使其能够在长期的游戏过程中不断积累经验和改进策略^{[13] [14] [15] [16]}。

2.1 博弈论与均衡策略

DeepHoldem 融合了博弈论和深度学习，通过计算均衡策略来应对德州扑克中的不确定性，它的整体框架如图 6 所示^[15]。具体来说，DeepHoldem 使用近端策略优化算法建模德州扑克游戏，在训练过程中，DeepHoldem 会不断地采样游戏中的状态和动作，并计算每个动作的优势函数，基于这些优势函数，DeepHoldem

通过梯度上升法最大化游戏的期望收益，以监督演员网络的更新。这使得模型能够快速提炼游戏规则信息，获得更好的游戏策略，同时简化了训练过程。这种方法使得 AI 能够合理预测对手的手牌，并据此做出最优决策。




Fig. 6 DeepHoldem 框架

博弈均衡，这个看似简单的术语，实则蕴含着深奥的智慧。它教会了 AI 如何在不确定性的情况下，依然能够保持冷静和理智，通过巧妙的策略选择来最大化自己的收益。在德州扑克中，这种不确定性主要体现在每个玩家只能看到自己手中的牌以及部分公共牌面，而无法完全了解对手的手牌情况。这种情况下，如果 AI 仅仅依赖自己手中的牌来做出决策，那么很容易就会陷入被动和盲目。

然而，当 AI 掌握了博弈均衡的概念后，它就能够在这种不确定性中找到一种混合策略。这种策略不是简单地依赖于某一种固定的行动方案，而是根据对手可能的牌型和自己的牌力情况，灵活地调整自己的行动策略。通过计算每种可能手牌的概率，AI 能够更加准确地评估自己的胜算和对手的威胁，从而制定出更加合理的行动方案。

这种混合策略的制定，不仅考验了 AI 的计算能力和逻辑推理能力，更体现了 AI 在复杂环境中的适应性和学习能力。它让 AI 能够在长期博弈中保持稳定的优势，即使面对不同的对手和牌面情况，也能够从容应对、游刃有余。

2.2 强化学习的应用

强化学习是一种通过与环境互动来学习最优策略的方法。智能体通过执行动作并接收环境反馈来不断优化其行为策略。在强化学习中，智能体的目标是最大化累积奖励。强化学习在德州扑克 AI 中也被广泛应用，通过与对手或自身的反复对弈，AI 能够不断学习并改进其策略。张小川了一种以 DQN-S 模型作为网络的强化学习范式^[16]，其基础框架如图 7 所示。




Fig. 7 DQN-S 模型

AI 通过强化学习在不断重复的对局中调整策略，这一过程仿佛就像是一个智慧的生命体在不断试错、不断成长。它不仅仅是在简单地执行预设的程序或算法，而是在每一次对局中，都在根据对手的行为、牌面的变化以及自身的输赢情况，灵活地调整自己的策略。这种学习方式，让 AI 能够逐渐学会如何应对不同类型的对手，无论是稳健型、激进型还是欺骗型，它都能够迅速识别并作出相应的应对策略。

这种适应性是 AI 在博弈游戏中取得卓越表现的关键所在。因为在实际的比赛中，对手的类型是多种多样的，他们的行为模式和策略选择也是千变万化的。如果 AI 只能够应对一种或几种固定的对手类型，那么它在面对其他类型的对手时，就很容易陷入被动和困境。与博弈均衡不同的是，强化学习的适应性体现在 AI 对多方面场景的适应性，而博弈均衡，则体现在 AI 在面对博弈情景时所选择的尽量最优的策略。强化学习的应用，让 AI 在博弈游戏中，实现了更为广泛的适应性。

更重要的是，这种学习方式不仅仅提高了 AI 在实际比赛中的表现，更让我们看到了 AI 未来发展的无限可能。它不仅仅可以应用于博弈游戏，更可以推广到更广泛的领域和场景中，如金融投资、军事战略、市场竞争等。在这些领域中，AI 同样需要面对复杂多变的环境和不同类型的对手，而它通过学习和调整策略来适应环境的能力，将为其在这些领域中的应用提供强大的支持。

3 围棋与德州扑克 AI 处理方法的对比

AI 在围棋与德州扑克中的不同处理方式反映了两者在信息结构、学习策略、决策过程、计算复杂度和心理推测等多个方面的根本差异。

3.1 信息结构

对于围棋来说，它是一种完全信息博弈，即 AI 可以获取整个游戏的状态，这意味着所有的棋盘信息都是公开的。AI 在围棋中可以利用深度神经网络和蒙特卡洛树搜索对所有可能的棋盘配置进行评估，逐步缩小搜索空间，最终找到最优解^[3]。在这种完全信息的环境中，AI 能够通过精确的计算和大量的数据训练，获得对整个棋局的全局把握。相比之下，德州扑克是一种不完全信息博弈，因为玩家只能看到自己手中的牌和公共牌，而无法得知其他对手的手牌信息。因此，AI 必须通过概率推断和对手建模来弥补信息缺失。这使得德州扑克 AI 在处理策略时更加注重对不确定性的应对，需根据历史数据推断对手的行为模式，从而进行最优决策。

这种信息结构的差异导致了两种 AI 在策略和实现上的根本不同，围棋 AI 侧重于全局信息的深度评估，而德州扑克 AI 则需要处理大量的不确定性和对手的可能行为。

3.2 学习方式

围棋 AI 的主要学习方式是通过自我对弈不断优化策略网络和价值网络^[7]。自我对弈能够让 AI 在没有人类干预的情况下,通过不断尝试不同的走法和策略,最终找到最佳解决方案。这种方法使得围棋 AI 能够迅速提高自身的棋艺水平,并在深度学习的帮助下,从最初的模仿学习逐步过渡到强化学习,通过大量的自我对弈不断优化自身的策略。德州扑克 AI 更加强调在不完全信息下如何处理对手的行为模式,并通过博弈均衡和强化学习找到合适的应对策略^[15]。德州扑克的复杂性还在于每一轮下注的不同策略和心理战术的运用, AI 需要通过大量对局来识别不同对手的行为模式,并相应调整其策略,从而找到博弈中的均衡点。

与围棋 AI 相比,德州扑克 AI 更加侧重于适应性学习,通过不断推测对手的意图和行为,来提高自身的胜率。

3.3 算资源与时间复杂度

围棋 AI 通常需要大量的计算资源来处理全局搜索和复杂的棋盘评估。围棋的棋盘状态组合极为庞大,因此,围棋 AI 依赖深度神经网络和蒙特卡洛树搜索的结合,通过大量的并行计算和高效的搜索算法来评估每一步的价值,这种方式需要消耗极大的计算资源和时间,特别是在对抗人类顶级棋手时。德州扑克 AI 则更强调实时决策能力以及对不完全信息的快速反应。由于德州扑克涉及多轮下注,每一轮的决策都可能影响整局游戏的结果, AI 必须在短时间内做出决策,这使得德州扑克 AI 更倾向于使用灵活的策略调整和对对手建模,来应对牌局中的不确定性和快速变化。

这种区别使得德州扑克 AI 在算法上更倾向于使用灵活的策略调整和对对手建模,而围棋 AI 则更多地依赖于庞大的计算能力和深度学习模型的高效评估。

4 当前 AI 在游戏上的发展

在多人在线战斗竞技场 (MOBA) 游戏领域, OpenAI 开发的 OpenAI Five^[17] 利用强化学习技术,通过每 2 秒从大约 200 万帧的批次中学习,有效解决了时间跨度长、信息不完善和复杂性等问题。在国内,腾讯公司在 2020 年上半年通过强化学习训练“演员——评论家网络”^[18],使得在 1V1 的场景下, AI 代理在训练后能够击败职业玩家。之后, AI-LAB 进一步研发了一种新颖的学习方法,通过训练和扮演大量英雄,巧妙地解决了可扩展性问题^[19],实现了能够处理由 Agent 组合形成的动作空间爆炸。以国内流行的《王者荣耀》为例,研发团队推出了基于监督学习的 AI——JueWu-SL^[20],将 MOBA 游戏的宏策略和微观管理以监督和端到端的方式集成到神经网络中进行训练,使得 AI 在 5V5 的环节中表现出色。




Fig. 8 《王者荣耀》的网络模型结构

在 NPC 的改进方面,国内研究者通过结合强化学习和蒙特卡洛树搜索等决策技术,改进了 NPC 的行为策略,使得他的行为更加得智能和人性化^[21]。例如,在最近备受瞩目的游戏《黑神话:悟空》中, AI 的应用使得 NPC 能够生成独特的对话内容,并根据玩家的游戏风格和进度调整对话策略,从而显著提高了玩

家的游戏体验。



Fig. 9 AI 助力高性能体验



Fig. 10 NPC 的协同、战斗 AI

三 总结

展望未来，AI 在游戏行业的发展将继续向智能化和人性化迈进，不仅提升游戏 AI 的决策效率与策略适应性，也会让 NPC 表现更加生动逼真。强化学习、深度学习和博弈论等技术的结合将进一步推动 AI 代理的智能化水平，使其在应对复杂的多玩家环境中表现得更加出色。此外，生成式 AI 的引入也可能使游戏中的情节和对话更加个性化，为玩家带来独特且沉浸式的游戏体验。AI 在游戏领域的应用前景广阔，必将为游戏开发者和玩家开创全新的互动方式和娱乐体验。

四 参考文献

- [1] Guo J, Zhang R, Peng S, et al. Efficient Symbolic Policy Learning with Differentiable Symbolic Expression[A/OL]. 2023: arXiv:2311.02104. arXiv: 2311.02104.
- [2] DIDDIGI R B, JAIN P, J P K, et al. Neural network compatible off-policy natural actor-critic algorithm [C/OL]//2022 International Joint Conference on Neural Networks (IJCNN). 2022: 1-10. DOI: 10.1109/IJCNN55064.2022.9892303.
- [3] SILVER D, HUANG A, MADDISON C J, et al. Mastering the game of go with deep neural networks and tree search[J/OL]. Nature, 2016, 529(7587): 484-489. <https://doi.org/10.1038/nature16961>.
- [4] Cazenave T. Monte Carlo Search Algorithms Discovering Monte Carlo Tree Search Exploration Terms [A/OL]. 2024: arXiv:2404.09304. arXiv: 2404.09304.
- [5] Cazenave T. Monte Carlo Game Solver[A/OL]. 2020: arXiv:2001.05087. arXiv: 2001.05087.
- [6] Cazenave T. Batch Monte Carlo Tree Search[A/OL]. 2021: arXiv:2104.04278. arXiv: 2104.04278.
- [7] SILVER D, SCHRITTWIESER J, SIMONYAN K, et al. Mastering the game of go without human knowledge[J/OL]. Nature, 2017, 550(7676): 354-359. <https://doi.org/10.1038/nature24270>.
- [8] 王振宇. 围棋自对弈系统在高性能运算集群上的构建与实现[D]. 北京邮电大学, 2019.
- [9] SILVER D, SCHRITTWIESER J, SIMONYAN K, et al. Mastering the game of go without human knowledge[J/OL]. Nature, 2017, 550: 354-359. <https://doi.org/10.1038/nature24270>.
- [10] 杜康豪, 宋睿卓, 魏庆来. 强化学习在机器博弈上的应用综述[J/OL]. 控制工程, 2021, 28(10): 1998-2004. DOI: 10.14107/j.cnki.kzgc.20200033.
- [11] ZHAO E, YAN R, LI J, et al. Alphaholdem: High-performance artificial intelligence for heads-up no-limit poker via end-to-end reinforcement learning[J/OL]. Proceedings of the AAAI Conference on Artificial Intelligence, 2022, 36(4): 4689-4697. <https://doi.org/10.1609/aaai.v36i4.20394>.
- [12] NICOLAI G, HILDERMAN R J. No-limit texas hold'em poker agents created with evolutionary neural networks[C/OL]//2009 IEEE Symposium on Computational Intelligence and Games. 2009: 125-131. DOI: 10.1109/CIG.2009.5286485.
- [13] LAZARIDIS A, PERCHANIDIS C, CHOVARIDAS D, et al. Alphabluff: An ai-powered heads-up no-limit texas hold' em poker video game[C/OL]//2022 International Conference on INnovations in Intelligent SysTems and Applications (INISTA). 2022: 1-6. DOI: 10.1109/INISTA55318.2022.9894244.
- [14] XIAOCHUAN Z, SONG D, HAILU Z, et al. A method of computing winning probability for texas hold'em poker[C/OL]//2021 33rd Chinese Control and Decision Conference (CCDC). 2021: 1820-1824. DOI: 10.1109/CCDC52312.2021.9601881.

-
- [15] WANG K, BAI D, ZHOU Q. Deepholdem: An efficient end-to-end texas hold'em artificial intelligence fusion of algorithmic game theory and game information[C/OL]//2022 IEEE 8th International Conference on Computer and Communications (ICCC). 2022: 2313-2320. DOI: 10.1109/ICCC56324.2022.10065796.
- [16] ZHANG X C, LI Y. A texas hold' em decision model based on reinforcement learning[C/OL]//2020 Chinese Control And Decision Conference (CCDC). 2020: 3814-3817. DOI: 10.1109/CCDC49329.2020.9164345.
- [17] OpenAI, :, Berner C, et al. Dota 2 with Large Scale Deep Reinforcement Learning[A/OL]. 2019: arXiv:1912.06680. arXiv: 1912.06680.
- [18] Ye D, Liu Z, Sun M, et al. Mastering Complex Control in MOBA Games with Deep Reinforcement Learning[A/OL]. 2019: arXiv:1912.09729. arXiv: 1912.09729.
- [19] Ye D, Chen G, Zhang W, et al. Towards Playing Full MOBA Games with Deep Reinforcement Learning [A/OL]. 2020: arXiv:2011.12692. arXiv: 2011.12692.
- [20] YE D, CHEN G, ZHAO P, et al. Supervised learning achieves human-level performance in moba games: A case study of honor of kings[J/OL]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(3): 908-918. DOI: 10.1109/TNNLS.2020.3029475.
- [21] HU Z, DING Y, WU R, et al. Deep learning applications in games: a survey from a data perspective [J/OL]. Applied Intelligence, 2023, 53: 31129-31164. DOI: 10.1007/s10489-023-05094-2.